Cesar School

Ciência da Computação

Théo de Albuquerque Moura

Orientador: Daniel Bezerra

Modelagem de Padrões de Opiniões Políticas a partir de pautas ideológicas

1. Introdução

Nas eleições presidenciais dos EUA de 2024, apesar de a maioria das pesquisas apontar uma disputa muito apertada e em geral indicar vantagem para Kamala Harris, Trump acabou conquistando uma vitória razoavelmente confortável, o que foi confirmado pelos resultados oficiais do FEC com 312 votos no Colégio Eleitoral contra 226 e cerca de 49,8 por cento a 48,3 por cento no voto popular. Levantamentos finais como PBS NewsHour NPR Marist na véspera da votação e séries da Reuters Ipsos indicavam pequena liderança ou empate técnico a favor de Harris, o que ajudou a consolidar expectativas que não se confirmaram na apuração. (FEC.gov)

Os resultados eleitorais recentes expõem limites importantes dos modelos de previsão baseados exclusivamente em características demográficas agregadas e intenção de voto por partido. Embora idade, renda, escolaridade, gênero, etnia, religião e região continuem informativas, a dinâmica contemporânea do voto mostra que eleitores organizam suas preferências em torno de pautas específicas, entendidas como conjuntos de temas como economia, segurança pública, combate à corrupção, imigração, meio ambiente, direitos reprodutivos, igualdade étnica e de gênero, entre outros. Em contextos de comunicação política altamente fragmentados, coalizões eleitorais tendem a emergir menos de identidades partidárias estáveis e mais do encadeamento de posições em pautas que, combinadas, aproximam segmentos sociais distintos de determinados partidos. Esta pesquisa será aplicada explicitamente ao caso dos Estados Unidos, tomando o eleitorado americano como universo empírico. Para embasar o enfoque em pautas, recorremos à literatura de issue voting e saliência que demonstra como temas estruturam preferências e coalizões. (Cambridge University Press & Assessment)

Este projeto parte da premissa de que é possível modelar padrões de opiniões por pauta a partir de variáveis demográficas e, em seguida, quantificar o quanto esses padrões explicam a decisão de voto por partido no contexto dos EUA. Em termos práticos, propõe-se i) estimar, com base em variáveis demográficas, a probabilidade de um indivíduo adotar certas posições em pautas específicas e ii) investigar, com rigor estatístico e de aprendizado de máquina, qual é a relevância relativa dessas pautas na escolha do partido. Ao longo do estudo, busca-se também identificar quais técnicas de aprendizado são ideais para esse tipo de problema, equilibrando desempenho preditivo, interpretabilidade e robustez, e estabelecer um protocolo replicável de validação. Como base de dados aberta, utilizaremos o American National Election Studies que reúne medidas de demografia, atitudes por tema e comportamento de voto. (ANES)

1.1 Motivação/Contexto

A literatura de comportamento eleitoral reconhece, há décadas, a importância de temas salientes na formação de preferências políticas. No entanto, as tentativas de previsão costumam privilegiar modelos mais simples, com foco predominantemente demográfico, que não capturam suficientemente a heterogeneidade de opiniões por pauta nem suas interações. Em sociedades plurais como os Estados Unidos, uma mesma combinação demográfica pode engendrar padrões distintos de opinião quando se mudam o contexto territorial, a trajetória ocupacional, a socialização religiosa ou o ciclo geracional. Além disso, o peso de cada pauta varia entre grupos e ao longo do tempo. A proposta de modelagem em duas etapas considera, primeiro, a estimação de padrões de opinião por pauta a partir de demografia e, depois, o uso desses padrões para explicar a decisão de voto partidária, em consonância com evidências acumuladas sobre a centralidade de issues na competição política. (Cambridge University Press & Assessment)

Em paralelo, a disponibilidade de microdados de surveys eleitorais dos EUA como o ANES que coletam demografia, intenção de voto e atitudes por tema e o progresso em técnicas de aprendizado de máquina permitem revisitar a questão com ferramentas mais adequadas à complexidade atual. O projeto também incorpora procedimentos de interpretação de modelos, como explicações baseadas em SHAP, e visualizações como curvas de dependência parcial, além de práticas de calibração de probabilidades como isotônica e Platt. (ACM Digital Library)

1.2 Problema de Pesquisa

O problema que orienta esta pesquisa, aplicada ao caso dos Estados Unidos, pode ser sintetizado em duas perguntas complementares:

- Pergunta principal
  Como modelar padrões de opiniões políticas por pautas específicas a partir de variáveis demográficas e, com base nesses padrões, estimar a relevância de cada pauta na decisão de qual partido receberá o voto?
- Perguntas derivadas
  i) Em que medida diferentes técnicas de aprendizado como regressões penalizadas,

modelos aditivos, árvores e florestas, boosting, modelos bayesianos e modelos de classes latentes se mostram ideais para prever atitudes por pauta a partir de demografia, considerando desempenho e interpretabilidade?
ii) Quais pautas e quais combinações de pautas exercem maior influência na decisão de voto por partido depois de controladas as variáveis demográficas?
iii) Em que medida os efeitos são heterogêneos entre subgrupos demográficos, por exemplo interação entre escolaridade e religião, entre etnia e região, entre gênero e coorte geracional?

Operacionalmente, a variável dependente final será a escolha partidária em classificação multiclasse. Os desfechos intermediários são as posições em pautas específicas em escalas ordinais, contínuas ou binárias. As variáveis independentes principais são demográficas: idade, gênero, etnia, escolaridade, renda, ocupação ou setor, religião ou afiliação, estado civil, presença de filhos, região ou estado e condição urbano rural.

1.3 Justificativa

A justaposição entre demografia e pautas oferece dupla contribuição no contexto dos EUA.

1. Contribuição teórica e analítica. Ao modelar explicitamente a etapa intermediária de opiniões por pauta inferidas a partir de demografia, o projeto permite decompor a relação entre perfil social e voto e identificar mecanismos. Exemplo: a maior probabilidade de posição A em pauta econômica, dada a escolaridade e a ocupação, explica uma fração mensurável do aumento na probabilidade de votar em determinado partido. Essa estratégia é mais informativa do que abordagens que pulam diretamente de demografia para voto, pois torna visíveis elos causais plausíveis sustentados pela literatura de issues e saliência. (Cambridge University Press & Assessment)
2. Contribuição metodológica e aplicada. Ao comparar técnicas de aprendizado sob critérios de desempenho, calibração e interpretabilidade, a pesquisa oferece um guia prático para estudos eleitorais nos Estados Unidos que precisam conciliar precisão e transparência. Serão contempladas, entre outras, regressão multinomial com e sem hierarquia, GLMs penalizados como lasso e elastic net, GAMs, árvores de decisão, random forests, gradient boosting como XGBoost e LightGBM, BART como Bayesian Additive Regression Trees, modelos de classes latentes para capturar coalizões de pauta e modelos hierárquicos bayesianos para permitir variação entre estados ou coortes. O plano inclui ferramentas de interpretação e calibração reconhecidas na literatura de ciência de dados. (ACM Digital Library)

Do ponto de vista social, previsões mais transparentes e mediadas por pautas favorecem diagnósticos menos estereotipados sobre grupos e mais úteis ao debate público. Do ponto de vista técnico, o projeto enfatiza boas práticas como validação cruzada estratificada, partições temporais quando aplicável, calibração isotônica ou Platt, uso de métricas múltiplas como log loss, Brier score, acurácia balanceada, F1 por classe e curvas de calibração, análise de estabilidade com bootstrap e interpretabilidade por coeficientes padronizados, efeitos

marginais, PDP e ICE e SHAP, com atenção a vieses amostrais e, quando necessário, ponderações do desenho amostral. (Cornell CS)

1.4 Objetivos

Objetivo Geral

Desenvolver e avaliar, no contexto dos Estados Unidos, um modelo que i) estime padrões de opiniões por pautas específicas a partir de variáveis demográficas e ii) quantifique a relevância relativa dessas pautas na decisão de voto por partido, comparando diferentes técnicas de aprendizado quanto a desempenho, calibração e interpretabilidade.

Objetivos Específicos

i) Construir a base analítica integrando microdados de surveys eleitorais abertos dos EUA que contenham, no mínimo, demografia, atitudes por pauta e intenção ou registro de voto por partido, com limpeza, harmonização de variáveis e documentação de dicionários e pesos amostrais. (ANES)

ii) Definir e operacionalizar pautas como economia e tributação, segurança, corrupção, imigração, meio ambiente, saúde, educação e direitos civis, distinguindo posição como favor, contra e intensidade, e saliência como importância atribuída, e derivar índices quando necessário.

iii) A modelagem de opiniões por pauta a partir de demografia. Testar GLMs penalizados como lasso e elastic net, GAMs para capturar não linearidades suaves, árvores, random forests, gradient boosting, BART e modelos de classes latentes para identificar padrões de coalizões de pauta inferidas de perfis demográficos e escolher modelos com melhor compromisso entre desempenho e interpretabilidade. (ACM Digital Library)

iv) Decisão de voto partidária. Modelar a escolha de partido em multiclasse usando como preditores os padrões de pauta estimados e, como controles, as variáveis demográficas. Comparar especificações como multinomial, hierárquico bayesiana, boosting e BART multinomial, com foco em calibração e generalização. (Cornell CS)

v) Comparar técnicas de aprendizado de forma sistemática com validação cruzada estratificada por partido e avaliação por coortes temporais ou regionais quando viável. Produzir ranking de métodos ideais por cenário como amostras pequenas e grandes, poucas e muitas pautas e forte desequilíbrio entre partidos.

vi) Quantificar a relevância das pautas na decisão de voto por partido por meio de efeitos marginais, decomposição SHAP, curvas de dependência parcial e análises contrafactuais simples que alteram posições e saliência de pautas e observam a mudança prevista na probabilidade de voto por partido. (ACM Digital Library)

vii) Avaliar heterogeneidades e interações entre demografia e pautas, por exemplo como escolaridade modifica o efeito de uma pauta econômica, como religião modera pautas de costumes e como etnia e região interagem em segurança pública.

viii) Estabelecer critérios de transparência e reprodutibilidade com publicação, sempre que eticamente e legalmente possível, de scripts, dicionários de variáveis e relatórios de validação, além de documentação de decisões de pré processamento, métricas e limites.

ix) Comparar com modelos tradicionais que vão de demografia para voto para estimar o ganho de desempenho e, sobretudo, o ganho explicativo ao incluir a camada de pautas.

x) Produzir um relatório interpretável que sintetize quais técnicas de aprendizado são mais indicadas para cada tipo de problema e quais pautas, isoladas e em combinação, têm maior peso na escolha partidária no eleitorado dos EUA, com implicações para a pesquisa e para a compreensão pública do voto.

Observações metodológicas com integração aos objetivos

- Variável alvo 1 intermediária: posição e saliência em cada pauta em escala binária, ordinal ou contínua. Variável alvo 2 final: partido escolhido em multiclasse.
- Particionamento e validação: treinos com validação cruzada estratificada por partido, avaliação de calibração por reliability curves e análise da distribuição de erros por grupo para detectar vieses.
- Interpretação: em modelos paramétricos, uso de coeficientes padronizados e efeitos marginais. Em modelos de árvore e ensemble, uso de importâncias, PDP e ICE e SHAP para explicações local e global. Em modelos latentes, descrição substantiva das classes de pauta e sua distribuição demográfica. (ACM Digital Library)
- Robustez e sensibilidade: análises com e sem pesos amostrais, testes de estabilidade temporal e regional, checagem de sobreajuste, comparação entre métricas como acurácia, log loss e Brier e calibração fora da amostra. (Cornell CS)
- Ética e privacidade: uso exclusivo de dados públicos e anonimizados do contexto norte americano, com divulgação responsável de resultados e prevenção de reidentificação ou estigmatização de grupos. (ANES)

Este projeto propõe uma estratégia clara e escalável para modelar padrões de opiniões políticas por pautas específicas a partir de variáveis demográficas e estimar o peso de cada pauta na decisão sobre qual partido recebe o voto no eleitorado dos Estados Unidos. Ao comparar técnicas de aprendizado sob critérios de desempenho, calibração e interpretabilidade, o estudo pretende oferecer uma referência metodológica sólida para pesquisas eleitorais que demandam precisão sem abrir mão da transparência analítica e que dialogam com a evidência de 2024 em que pesquisas finais indicavam ligeira vantagem para Harris mas o resultado oficial favoreceu Trump por margem confortável no Colégio Eleitoral. (PBS)

2. FUNDAMENTAÇÃO TEÓRICA E TRABALHOS RELACIONADOS

Este capítulo apresenta os principais referenciais teóricos e metodológicos que orientam o projeto. A ideia não é esgotar a literatura, mas destacar conceitos e resultados que ajudam a justificar a modelagem em duas etapas proposta — primeiro, atitudes por pauta; depois, escolha partidária — usando dados do eleitorado norte-americano.

A revisão está organizada em três blocos: (i) modelos clássicos de comportamento eleitoral, com ênfase em identificação partidária e voto racional/retrospectivo; (ii) literatura sobre *issue voting*, saliência e propriedade de pauta; e (iii) contribuições sobre demografia, formação de atitudes e métodos de modelagem estatística aplicados a dados eleitorais, incluindo trabalhos empíricos relacionados.

2.1 Modelos Clássicos de Comportamento Eleitoral

2.1.1 Identificação partidária e o "funil de causalidade"

A chamada Escola de Michigan, sintetizada em *The American Voter* (CAMPBELL et al., 1960) e atualizada em *The American Voter Revisited* (LEWIS-BECK et al., 2008), propõe que a decisão de voto é resultado de um processo de longo prazo, no qual a **identificação partidária** ocupa papel central. A ideia do "funil de causalidade" resume esse processo: fatores sociais e históricos (família, classe, religião, contexto comunitário) moldam gradualmente uma identidade partidária estável, que por sua vez influencia atitudes políticas e, ao final, a escolha eleitoral.

Nessa perspectiva, a identificação partidária funciona como uma espécie de "atalho cognitivo": eleitores tendem a enxergar candidatos, programas e eventos à luz de sua preferência partidária, o que ajuda a explicar a relativa estabilidade de padrões de voto ao longo do tempo. Ao mesmo tempo, estudos mais recentes apontam que esse vínculo psicológico continua importante, mas convive com maior volatilidade, crescimento de independentes e papel crescente de temas específicos em algumas eleições.

2.1.2 Teoria da escolha racional e voto retrospectivo

Em contraste com o enfoque psicológico, a teoria da escolha racional entende o voto como resultado de um cálculo de utilidade. Em *An Economic Theory of Democracy*, Downs (1957) modela eleitores e partidos em um espaço ideológico: partidos escolhem posições e eleitores votam no partido mais próximo de suas preferências. Essa abordagem pressupõe um certo nível de informação e capacidade de comparar alternativas.

Fiorina (1981) complementa esse quadro com a ideia de **voto retrospectivo**: em vez de antecipar todas as consequências futuras, eleitores avaliam o desempenho passado dos governantes, sobretudo na economia, e decidem se "recompensam" ou "punem" o incumbente. Assim, a decisão pode ser razoavelmente racional mesmo com informação limitada.

Na prática, muitos estudos combinam essas perspectivas: identidades partidárias fornecem uma base relativamente estável, enquanto avaliações retrospectivas e questões específicas ajudam a explicar variações de curto prazo e decisões de eleitores menos fortemente identificados.

2.2 *Issue voting*: posições, valência, saliência e propriedade de pauta

A literatura de *issue voting* busca entender como **pautas específicas** – como economia, imigração, segurança pública ou meio ambiente – entram na decisão de voto.

2.2.1 Questões posicionais e questões de valência

Stokes (1963) diferencia duas categorias de temas:

- **Questões posicionais**: dividem eleitores e partidos em posições opostas em um contínuo (por exemplo, mais ou menos impostos; mais ou menos intervenção estatal).
- **Questões de valência**: tratam de objetivos amplamente desejáveis (crescimento econômico, combate à criminalidade, redução da corrupção), nos quais a disputa principal é sobre quem é mais competente para alcançá-los.

Modelos posteriores (por exemplo, MACDONALD; RABINOWITZ; LISTHAUG, 1998; ANSOLABEHERE; SNYDER, 2000) mostram que campanhas costumam combinar as duas dimensões: ao mesmo tempo em que sinalizam posições, procuram construir ou reforçar uma imagem de competência geral em certas áreas.

2.2.2 Teoria da saliência

Budge e Farlie (1983) argumentam que partidos não competem apenas ajustando suas posições, mas também decidindo **quais temas enfatizar**. Em vez de mudar radicalmente de posição, um partido pode simplesmente falar mais de uma pauta que o favorece e menos de outra em que é visto como fraco – estratégia conhecida como *selective emphasis*.

Do ponto de vista da modelagem, isso implica que a importância subjetiva atribuída a uma pauta (sua **saliência**) pode ser tão relevante quanto a posição do eleitor em si. Dois indivíduos com a mesma posição sobre imigração podem votar de forma diferente se, para um deles, essa pauta for muito mais importante do que para o outro.

2.2.3 Propriedade de pauta (*issue ownership*)

Petrocik (1996) introduz o conceito de **propriedade de pauta** (*issue ownership*): certos partidos são historicamente vistos como mais competentes em determinados temas. No caso norte-americano, estudos apontam que Republicanos costumam ser associados a defesa, combate ao crime e redução de impostos, enquanto Democratas são percebidos como mais fortes em saúde, educação e proteção ambiental.

Quando uma eleição é dominada por pautas “proprietárias” de um partido, esse partido tende a ser beneficiado. Trabalhos como Van der Brug et al. (2004) e Damore (2004) mostram que isso ocorre tanto em nível agregado (desempenho eleitoral geral) quanto em nível individual (decisão de voto), com efeitos que variam conforme o interesse político e a exposição à informação.

2.2.4 Agenda-setting e formação de preferências

A teoria do *agenda-setting* (McCOMBS; SHAW, 1972) destaca o papel da mídia na definição daquilo sobre o que as pessoas pensam. O argumento principal é que, ao selecionar temas e dar mais ou menos espaço a cada um, veículos influenciam a agenda pública e, portanto, a saliência percebida de determinados problemas.

Em contextos de alta polarização e fragmentação informacional, como os EUA recentes, diferentes grupos podem ter “agendas” bastante distintas. Isso reforça a importância de mensurar não apenas **posições** sobre pautas, mas também sua **importância subjetiva**, que pode ser afetada por exposição seletiva a meios de comunicação e redes sociais.

2.3 Demografia, crenças e atitudes políticas

Converse (1964), ao examinar sistemas de crenças políticas em públicos de massa, mostrou que a maioria dos cidadãos não organiza suas opiniões de maneira plenamente ideológica. Em vez de um conjunto coerente de princípios abstratos, o que se observa com frequência é um conjunto de atitudes pontuais, influenciadas por demografia, contexto e experiências.

Características como **escolaridade, renda, idade, etnia, religião e região** ajudam a estruturar essas atitudes, mas não determinam automaticamente o voto. Processos de socialização, redes de interação, exposição a notícias e eventos específicos também exercem papel importante.

A estratégia deste trabalho – modelar primeiro **atitudes por pauta a partir da demografia** e, em seguida, **a escolha partidária a partir dessas atitudes e das próprias variáveis demográficas** – dialoga com essa visão intermediária. Em vez de supor que demografia “leva diretamente” ao voto, admite-se que ela influencia, antes, a forma como eleitores se posicionam em temas concretos.

2.4 Fonte de dados: American National Election Studies (ANES)

O **American National Election Studies (ANES)** é uma das principais fontes de dados para estudos sobre comportamento eleitoral nos Estados Unidos, com séries que remontam a 1948. Os estudos combinam amostras representativas, questionários detalhados e documentação extensa, permitindo análises comparáveis ao longo do tempo.

Para este projeto, interessam especialmente as ondas mais recentes (incluindo 2020 e 2024), que contém:

- Variáveis demográficas padronizadas (idade, gênero, escolaridade, renda, etnia, religião, região, entre outras);
- Itens sobre **posições e importância atribuída a múltiplas pautas**, como economia, imigração, saúde, meio ambiente, direitos civis etc.;
- Informações sobre **intenção de voto** e, em alguns casos, validação do voto em registros oficiais;
- Pesos amostrais e documentação metodológica que permitem análises mais cuidadosas.

Essas características tornam o ANES adequado para implementar, em escala reduzida, o tipo de modelagem em duas etapas discutido na introdução.

2.5 Métodos de modelagem para atitudes e comportamento eleitoral

Este trabalho é um TCC e, portanto, não pretende cobrir todas as possibilidades de modelagem existentes. A fundamentação abaixo se concentra em **algumas famílias de modelos** que serão efetivamente usadas ou que ajudam a justificar escolhas metodológicas simples.

2.5.1 Modelos lineares generalizados e aditivos

Modelos lineares generalizados (GLMs), como regressões logísticas e regressões ordinais, são amplamente utilizados em ciência política para analisar variáveis categóricas, incluindo voto e atitudes políticas. Esses modelos permitem relacionar probabilidades de certos desfechos (por exemplo, posição favorável ou contrária a uma pauta) a um conjunto de preditores demográficos.

Em contextos com muitas variáveis ou interações possíveis, técnicas de **penalização** como LASSO e Elastic Net (ZOU; HASTIE, 2005) ajudam a evitar sobreajuste e a selecionar, de forma automática, preditores mais relevantes. Em um projeto de graduação, mesmo uma aplicação simples de penalização já é suficiente para ilustrar essa ideia.

Modelos aditivos generalizados (GAMs), por sua vez, permitem capturar relações não lineares suaves entre preditores e resposta (HASTIE; TIBSHIRANI, 1990). Eles podem ser úteis, por exemplo, para explorar efeitos de idade ou renda sem impor uma forma linear rígida. Neste trabalho, GAMs podem ser considerados como complemento exploratório aos modelos logísticos tradicionais, se o cronograma permitir.

2.5.2 Métodos baseados em árvores

Modelos de **árvores de decisão** e, em versão mais robusta, **random forests**, são alternativas intuitivas aos modelos lineares. Árvores dividem o espaço das variáveis explicativas em segmentos, produzindo regras do tipo “se escolaridade é alta e renda é baixa, então...”; random forests combinam muitas árvores para obter predições mais estáveis (BREIMAN, 2001).

Esses métodos são úteis quando se suspeita de interações complexas entre variáveis (por exemplo, entre religião e região ou entre etnia e escolaridade), mas não se deseja especificar

manualmente todas as interações em um modelo linear. Para um TCC, mesmo uma comparação simples entre regressão logística e uma random forest básica já ilustra bem as vantagens e limitações de cada abordagem.

2.5.3 Interpretabilidade e calibração em modelos simples

Em estudos eleitorais, não basta obter um "bom acerto": é importante que os modelos sejam **interpretáveis** e que as probabilidades preditas façam sentido substantivo.

- Em regressões, coeficientes e **efeitos marginais** ajudam a entender em que medida variáveis demográficas ou de pauta estão associadas a maior ou menor probabilidade de determinado voto.
- Em árvores e random forests, medidas simples de **importância de variáveis** e gráficos relacionando preditores e probabilidade predita (como gráficos de dependência parcial) permitem extrair insights.

Além disso, a literatura em aprendizado de máquina destaca a necessidade de verificar se as probabilidades previstas são **bem calibradas**, isto é, se valores próximos de 0,7, por exemplo, correspondem mesmo a eventos que ocorrem em cerca de 70% dos casos (NICULESCU-MIZIL; CARUANA, 2005). Para fins de TCC, é suficiente usar algumas métricas básicas – como acurácia, log-loss ou Brier score – e, quando viável, examinar uma curva de calibração simples.

Outras técnicas mais sofisticadas, como BART, análise de classes latentes ou explicações baseadas em SHAP, são mencionadas na literatura recente, mas ficam fora do escopo operacional deste projeto, podendo ser vistas como possibilidades para estudos futuros.

2.6 Trabalhos relacionados

Diversos estudos recentes combinam os elementos discutidos acima – comportamento eleitoral, pautas específicas e métodos quantitativos. Esta seção apresenta, de forma sintética, alguns deles, com destaque para a relação com o presente trabalho.

- **Bélanger (2005)** examina como **saliência de pautas e *issue ownership*** influenciam o voto, usando dados do Canada Election Study. O autor mostra que temas percebidos como importantes pesam mais na decisão quando associados a partidos vistos como competentes naquela área.
- **Lachat (2009)**, a partir de dados europeus, argumenta que a percepção de **competência temática** dos partidos pode ser mais decisiva do que a simples importância atribuída a um tema, reforçando o papel da propriedade de pauta na avaliação partidária.
- **Ansolabehere, Rodden e Snyder (2008)** utilizam dados do ANES para introduzir o conceito de "força" das *issues*, mostrando que estabilidade e coerência das posições temáticas ajudam a explicar o voto, o que reforça a importância de medir atitudes por pauta de forma estruturada.

- **Flavin (2022)** explora ondas do ANES entre 1996 e 2008 e conclui que a interação entre **proximidade ideológica** e **importância do tema** é relevante para explicar a escolha entre os grandes partidos, sugerindo que posição e saliência não devem ser analisadas isoladamente.
- **Leeper e Robison (2020)** questionam se medidas de "importância subjetiva" realmente aumentam o poder preditivo dos modelos de voto. Utilizando o ANES, encontram relações mais fracas do que a literatura muitas vezes supõe, o que convida a um uso cuidadoso dessas variáveis.
- **Hare (2024)** propõe o conceito de *priority voting*, argumentando que o que importa não é apenas declarar que um tema é importante, mas como os eleitores **priorizam problemas** quando precisam escolher entre alternativas em conflito.
- **Kim (2021)** aplica técnicas de *ensemble machine learning* a dados do ANES e de outros surveys para mostrar que, embora esses métodos aumentem o desempenho preditivo, o eleitorado não se torna necessariamente "mais previsível" ao longo do tempo, sinalizando limites estruturais para modelos de previsão eleitoral.
- **Camatarri (2025)** utiliza várias ondas do ANES para prever a votação popular em eleições presidenciais, com foco em modelos logísticos clássicos e bayesianos. O estudo reforça que modelos relativamente simples, quando bem fundamentados teoricamente, podem competir com abordagens mais complexas.
- **Montgomery e Olivella (2018)** apresentam um panorama didático sobre modelos baseados em árvores (como GBM e random forests) aplicados a dados de ciência política, discutindo vantagens, limitações e boas práticas de uso.

Em conjunto, esses trabalhos mostram que: (i) pautas e sua importância subjetiva têm papel relevante, mas não trivial, na decisão de voto; (ii) dados do ANES são amplamente utilizados para investigar esses temas; e (iii) tanto modelos tradicionais quanto técnicas mais recentes de aprendizado de máquina têm sido empregados para analisar comportamento eleitoral.

2.7 Síntese e implicações para o modelo proposto

A fundamentação teórica e os trabalhos relacionados apontam para alguns princípios que orientam o desenho empírico deste TCC:

1. **Mediação demografia → pautas → voto**
   A literatura sugere que variáveis demográficas influenciam o voto, em parte, por meio de suas conexões com atitudes em temas específicos. Faz sentido, portanto, adotar uma modelagem em duas etapas, estimando primeiro opiniões por pauta e, depois, a escolha partidária.
2. **Importância da saliência**
   Teorias de saliência, *issue ownership* e *agenda-setting* indicam que a relevância de uma pauta não depende apenas da posição do eleitor, mas também do peso que ele atribui a esse tema. Quando possível, o modelo empírico buscará incorporar medidas simples de importância subjetiva.
3. **Uso de modelos relativamente simples, porém comparáveis**
   Diante dos limites de tempo e escopo de um TCC, a estratégia é trabalhar com um

conjunto restrito de métodos – regressões (logísticas/ordinais), possivelmente com penalização, e ao menos um método baseado em árvores – que permitam comparar desempenho e interpretabilidade sem pretensão de cobrir todo o arsenal disponível.

4. **Equilíbrio entre desempenho e interpretação substantiva**
   Em vez de focar apenas na melhor métrica de predição, o interesse está também em entender como demografia e pautas se relacionam com o voto. Por isso, será dada atenção a efeitos marginais em regressões, importância de variáveis em modelos de árvore e algumas visualizações básicas.
5. **Verificação de limitações e incerteza**
   A literatura em aprendizado de máquina e comportamento eleitoral alerta para limites da previsibilidade, mesmo com métodos sofisticados. O projeto buscará, em escala compatível com um projeto de faculdade, que é o caso desse, apontar essas limitações e evitar interpretações deterministas dos resultados.

Em resumo, o capítulo 2 fornece o pano de fundo teórico e metodológico para a análise empírica que será desenvolvida nos capítulos seguintes, situando o trabalho em relação a debates clássicos sobre comportamento eleitoral, à literatura de pautas e saliência, e a um conjunto enxuto de ferramentas estatísticas aplicáveis aos dados do ANES.

3. Metodologia

A presente pesquisa caracteriza-se como um estudo quantitativo, de natureza explicativa e preditiva, aplicado ao comportamento eleitoral. A abordagem metodológica estrutura-se em duas etapas sequenciais de modelagem: primeiramente, a estimação de padrões de opinião (pautas) a partir de variáveis sociodemográficas e, subsequentemente, a modelagem da decisão do voto baseada nesses padrões e nos perfis demográficos.

3.1 Atividade de Pesquisa

A atividade de pesquisa será conduzida através de técnicas de Ciência de Dados e Aprendizado de Máquina (*Machine Learning*), utilizando dados secundários de alta confiabilidade. O processo analítico divide-se nas seguintes frentes de trabalho:

3.1.1 Fonte de Dados e Universo da Pesquisa

O universo empírico da pesquisa é o eleitorado dos Estados Unidos. A base de dados principal será o **American National Election Studies (ANES)**, especificamente as séries temporais (Time Series Studies) mais recentes, com foco nas ondas de 2020 e, se disponíveis os microdados consolidados, 2024.

O ANES é o padrão-ouro para pesquisas eleitorais acadêmicas nos EUA, fornecendo amostras probabilísticas representativas da população votante. A escolha por esta fonte justifica-se pela consistência das perguntas ao longo do tempo e pela riqueza de variáveis que cobrem simultaneamente:

1. **Perfil Demográfico Detalhado:** Idade, gênero, raça/etnia, nível educacional, renda familiar, afiliação religiosa, frequência a cultos, estado civil, região de residência (estado/condado) e situação ocupacional.
2. **Atitudes e Opiniões (Issues):** Perguntas escalares sobre posicionamento em temas como economia, saúde, imigração, aborto, controle de armas, meio ambiente e igualdade racial.
3. **Comportamento Político:** Intenção de voto declarada, identificação partidária e, em subamostras, validação do voto via registros oficiais.

3.1.2 Tratamento e Operacionalização das Variáveis

Antes da modelagem, será realizada uma etapa rigorosa de pré-processamento dos dados (*data wrangling*).

Variáveis Independentes (Preditores Demográficos):

Serão tratadas variáveis categóricas (como religião e etnia) através de codificação One-Hot Encoding ou Target Encoding, dependendo da cardinalidade. Variáveis ordinais (como escolaridade) serão preservadas numericamente ou tratadas como fatores ordenados. Valores ausentes (missing values) serão analisados quanto à sua aleatoriedade e tratados via imputação múltipla (MICE) ou imputação por K-Nearest Neighbors (KNN), para evitar a perda de poder estatístico.

Variáveis Intermediárias (Pautas/Issues):

As pautas serão operacionalizadas não apenas pela posição (favorável/contrário), mas, quando disponível, pela saliência (importância atribuída pelo eleitor). Serão criados índices compostos ou escalas via Análise Fatorial Exploratória (EFA) para reduzir a dimensionalidade de temas correlacionados, agrupando-os em dimensões latentes (ex: "Conservadorismo Social", "Intervencionismo Econômico").

Variável Dependente Final (Voto):

A variável alvo será a escolha partidária, tratada como um problema de classificação multiclasse (Democrata, Republicano, Outros/Abstenção).

3.1.3 Estratégia de Modelagem e Algoritmos

A análise será executada em dois estágios interconectados:

Estágio 1: Demografia -> Pautas

O objetivo é prever a probabilidade de um indivíduo adotar certas posições políticas dado seu perfil demográfico. Para isso, serão testados e comparados algoritmos que lidam bem com não-linearidades e interações complexas:

- **Regressão Logística Penalizada (Lasso/Elastic Net):** Para estabelecer uma *baseline* linear e selecionar variáveis.
- **Modelos Aditivos Generalizados (GAMs):** Para capturar relações não-lineares suaves (ex: efeito não-linear da idade no conservadorismo).
- **Árvores de Decisão e Random Forests:** Para capturar interações automáticas entre variáveis demográficas (ex: como a renda interage com a raça na determinação de visões econômicas).
- **Modelos de Classes Latentes (LCA):** Para identificar clusters de eleitores com perfis de opinião similares.

Estágio 2: Demografia + Pautas -> Voto

Utilizando as probabilidades de opinião estimadas no Estágio 1 como input, juntamente com os controles demográficos, modelar-se-á a decisão de voto.

- **Gradient Boosting (XGBoost / LightGBM):** Serão os algoritmos principais devido à sua alta capacidade preditiva em dados tabulares e robustez a dados desbalanceados.
- **Bayesian Additive Regression Trees (BART):** Será utilizado para fornecer intervalos de credibilidade para as previsões, oferecendo uma medida de incerteza estatística robusta.

3.1.4 Validação e Avaliação de Desempenho

Para garantir a generalização dos resultados e evitar sobreajuste (*overfitting*), será adotado um protocolo de validação cruzada estratificada (*Stratified K-Fold Cross-Validation*), mantendo a proporção de classes de voto em cada dobra.

As métricas de avaliação incluirão:

- **Log-Loss (Entropia Cruzada):** Métrica principal para avaliar a qualidade das probabilidades estimadas.
- **Brier Score:** Para medir a calibração das previsões.
- **AUC-ROC e F1-Score (Macro/Micro):** Para avaliar a capacidade de discriminação entre as classes partidárias.
- **Curvas de Calibração (Reliability Diagrams):** Serão plotadas para verificar se as probabilidades preditas correspondem às frequências observadas, aplicando técnicas de calibração Isotônica ou de Platt se necessário.

3.1.5 Interpretabilidade do Modelo

Dado o objetivo de "explicar" e não apenas "prever", a caixa-preta dos algoritmos de *Machine Learning* será aberta utilizando técnicas de *Explainable AI* (XAI):

- **SHAP (SHapley Additive exPlanations):** Para quantificar a contribuição marginal de cada pauta na probabilidade de voto (importância global) e explicar previsões individuais (importância local).

- **PDP (Partial Dependence Plots):** Para visualizar o efeito marginal médio de uma pauta na probabilidade de voto, mantendo as demais constantes.
- **ICE (Individual Conditional Expectation):** Para examinar a heterogeneidade dos efeitos das pautas entre diferentes indivíduos.

Todo o processamento será realizado utilizando as linguagens de programação **Python** (bibliotecas *scikit-learn, pandas, shap*) ou **R** (pacotes *tidymodels, bartMachine*), garantindo a reprodutibilidade através da disponibilização dos scripts em repositório controlado.

4. Cronograma

O cronograma a seguir detalha as atividades focadas na estruturação da pesquisa, fundamentação teórica e preparação rigorosa dos dados, cobrindo o período de setembro a dezembro.

Etapas / Meses (2024)	**Setembro**	**Outubro**	**Novembro**	**Dezembro**
1. Pesquisa Inicial e Definição do Tema	X			
Delimitação do problema de pesquisa e das hipóteses sobre issue voting.				
2. Levantamento Bibliográfico	X	X		
Busca e fichamento de artigos de referência (ex: teoria de saliência, ANES, ML em ciência política).				
3. Seleção e Obtenção do Dataset		X		
Download dos microdados do ANES e leitura da documentação técnica.				

4. Estudo das Variáveis (Codebook)		X	X	
Análise do dicionário de dados e escolha das colunas (features) demográficas e de pauta.				
5. Limpeza e Tratamento do Dataset			X	X
Tratamento de valores nulos (missings), padronização de escalas e filtros amostrais.				
6. Consolidação da Base de Dados				X
Exportação da base final limpa e documentação dos critérios de exclusão/inclusão.				

Referências

1. **Federal Election Commission (FEC).** *Official 2024 U.S. Presidential Election Results.* Disponível em: https://www.fec.gov.
2. **PBS NewsHour / NPR / Marist Poll.** *Final Pre-Election Survey (Oct 30 – Nov 3, 2024): Kamala Harris vs Donald Trump.* Disponível em: https://www.pbs.org/newshour/politics/poll-november-2024-harris-trump-marist-npr.
3. **Reuters / Ipsos.** *U.S. Presidential Election Polling Tracker 2024.* Disponível em: https://www.reuters.com/world/us/us-election-polls/.
4. **American National Election Studies (ANES).** *Time Series Study 2020–2024 Dataset.* ICPSR 38034, University of Michigan & Stanford University. Disponível em: https://electionstudies.org/data-center/.
5. **Lewis-Beck, M. S.; Jacoby, W. G.; Norpoth, H.; Weisberg, H. F.** *The American Voter Revisited.* Ann Arbor: University of Michigan Press, 2008.
6. **Carmines, E. G.; Stimson, J. A.** *Issue Evolution: Race and the Transformation of American Politics.* Princeton University Press, 1989.

7. **Molnar, C.** *Interpretable Machine Learning: A Guide for Making Black Box Models Explainable.* 2ª ed., 2022.
8. **Lundberg, S. M.; Lee, S. I.** *A Unified Approach to Interpreting Model Predictions (SHAP). Advances in Neural Information Processing Systems (NeurIPS)*, 2017.
9. **Regularization and Variable Selection via the Elastic Net** (ZOU & HASTIE, 2005): https://oa.mg/work/10.1111/j.1467-9868.2005.00503.x
10. **Random Forests** (BREIMAN, 2001): https://www.mfm.uchicago.edu/wp-content/uploads/2020/06/Breiman-Random-Forests.pdf
11. **Greedy Function Approximation: A Gradient Boosting Machine** (FRIEDMAN, 2001): https://www.cmi.ac.in/~madhavan/courses/dmml2025/literature/Friedman-Gradient-Boosting-Machine-2001.pdf
12. **The American Voter** (CAMPBELL et al., 1960): https://press.uchicago.edu/ucp/books/book/chicago/A/bo24047989.html